ScholarHub 大数据毕业设计新版实施方案

版本日期：2026 年 10 月 16 日 适用范围：当前代码基线之后的毕业设计开发与答辩

本版以 main 的 49448de 及当前工作区为起点，重新安排 ScholarHub 的后续工作。旧方案的大数据方向继续采用：业务 MySQL 提供数据，PySpark 与 Spark SQL 完成离线处理，汇总结果通过 FastAPI 和 Vue / ECharts 展示。主要更新是把已经完成的 CR1 至 CR9 整改移出待开发清单，并按当前可信来源、事务和权限规则设计数据管道。

项目已经具备较完整的业务与验证基础，后续以真实数据处理闭环、可复现实验和论文答辩为重点。本方案中的 Spark 作业、分析结果表与离线查询接口均为拟新增内容；本版编制不直接启动这些改造。

用户已说明导师目前没有指定数据规模、必须使用的技术或提交期限。本文给出可调整的四至六周节奏，首版固定三个学习行为指标。社区、教学分析与 AI 引导式工作流按剩余时间选择，生产治理及实时计算留待后续需求明确后推进。

阅读顺序：第 1 至 3 节说明变化、现状和目标；第 4、5、8 节作为数据与接口设计依据；第 6 节按阶段执行；第 9 至 12 节组织实验、论文和答辩；附录 A 为当前全部接口，附录 B 为独立阶段开发指令。

1 旧方案需要如何更新

1.1 更新结论

需要重写现状基线、任务排序、数据来源规则和验收安排。大数据技术主线仍然成立，现有业务表和前端也继续复用。代码改动较多，主要加强了工程正确性和使用流程，并未自动形成 Spark 数据处理能力。

旧方案的安排	当前事实	新版处理
学习进度与完成资格优先修复	CR6A 已采用真实任务计数、计划与任务锁协调，覆盖 199 / 200 与并发追加	移为已完成；新增分析按任务明细计算，保留回归
学习记录来源按 JSON 标记识别	CR6B 保留系统来源键，以真实 Feedback 关系决定教学来源	改写抽取与 DWD 来源规则，禁止直接相信 JSON.source
工作流编辑保护与 Context 规则尚需加强	CR1 至 CR3 已完善活动运行保护、后继失效和最终模型字段投影	保留当前机制；新增分析不修改工作流执行语义
账号缓存与异步切换存在风险	CR4 已处理退出、账号隔离及旧响应覆盖	新图表复用认证与请求归属机制
教学任务与课堂操作边界需整改	CR5、CR7、CR8 已修复 null 校验、重新核验和课堂分页	保留为现有能力及必要回归
完整浏览器主线待补证	CR9 最新真实接口浏览器记录已通过	现有业务基线已补齐；新增分析另做端到端验收
所有接口重新规范	当前路径和公开字段总体保留，内部规则发生完善	导出最新契约、补充行为说明，避免重复实现接口

旧方案的安排	当前事实	新版处理
Spark、ODS / DWD / ADS、离线图表待开发	仓库仍未发现对应依赖、作业和离线分析接口	作为本版核心新增工作
AI 引导会话与实时计算继续扩展	仍属独立设计路线	主线稳定后选择实施，不作为数据管道前置条件

1.2 本版与旧版的关系

20261015 版保留为历史计划。本版接替其后续任务排序；其中仍适用的指标、数据权限和批次原则已重新整理。旧计划、旧 PRODUCT 描述及早期阶段报告中的状态必须结合日期判断，不能用来覆盖当前源码和 CR9 证据。

完成过的修复继续维护测试，只有后续变更破坏这些规则时才再次修改。下一步可以从范围与契约收口进入数据抽取，随后完成 Spark 处理和结果展示。

2 当前项目基线与可复用成果

2.1 架构与接口

当前技术栈为 Vue 3、TypeScript、Pinia、Axios、Element Plus、Vue Flow、ECharts，以及 FastAPI、Pydantic、SQLAlchemy、MySQL 和 AI Provider。后端仍采用 Router → Service → Repository → Model，前端通过统一 API 模块访问服务端。

本版从当前 ORM 和实际生成的 OpenAPI 核对到 34 张业务表、81 个外键约束、17 个模块、96 个路径、136 项操作。方法分布为 GET 57、POST 52、PUT 10、PATCH 4、DELETE 13。接口数量与旧版相同，表示路径集合基本稳定，不表示接口行为或内部实现没有变化。

现有业务覆盖账号与校园身份、项目与课程、计划与任务、学习记录、社区治理、工作流、个人 AI 报告、班级与教学提交反馈。Campus Studio 页面与 ECharts 组件可以复用，后续增加独立离线分析入口即可。

2.2 已完成的质量基础

当前成果	代码或证据位置	后续需要保持的规则
活动工作流编辑保护与执行版本校验	workflow、workflow_execution Repository 及 CR1	运行中的图不能被并发改写
节点输入、连线和后继失效规则	Workflow Repository、Service 及 CR2	语义变化重算受影响后继，历史结果保留
模型字段投影与共享 Context 原子更新	agents/base.py、project_context、CR3	最终消息遵循合法读取集合，跨工作流失效一致
账号隔离与最新请求生效	认证 client、Store、CR4	A 的缓存、401 或旧请求不能影响 B
教学任务 null 边界	schemas/teaching.py、CR5	必填不能显式清空，可空字段仍允许清空
计划真实完成资格与锁协调	repositories/learning.py、CR6A	任务数大于零且全部完成才允许完成计划
可信教学来源与编辑保护	LearningRecord.teaching_feedback、CR6B	来源由 ACCEPT Feedback 关系证明，客户端不能伪造系统字段
校园重新核验与课堂分页	campus、TeachingClassView、CR7 / CR8	只有合法新邀请能恢复指定身份，后页内容可操作
综合业务验收	CR9 报告与测试证据	新开发保留现有主线与隔离边界

最新已归档的 CR9 与 GitHub 交付记录包含后端 271 项测试、前端类型与构建、隔离 MySQL 主线和专项验证。CR9 的真实接口浏览器记录为 browser_mainline passed、150 次 API 请求、pageErrors 为 0，并记录测试数据清理通过。它们是当前可复用的历史验收基线，不等于新增 Spark 功能已经通过验证。

2.3 尚未形成的能力

当前 statistics 仍直接聚合 MySQL 业务表，个人 AI 报告仍基于服务端收集的事实快照；两者都不是 Spark 结果。依赖和业务目录中未发现 SparkSession、PySpark 作业或 ODS / DWD / ADS 管道。

自然语言生成实践流程、human_checkpoint、等待学生提交和恢复的引导会话，也不能由现有 CR 整改推断为已实现。CR 完善了原工作流基础，并没有把旧引擎自动升级为新的引导式实践系统。

3 毕业设计目标与范围

3.1 题目与研究问题

建议与导师沟通的题目为“基于 Spark 的校园学习行为分析与可视化系统设计与实现”。现有 AI 能力作为应用辅助功能；如果以后把 AI 引导写成主要研究点，再增加对应实现和质量评价。

研究问题聚焦于：业务记录如何转化为可复现的分析快照；清洗、来源识别与时间口径如何保障指标可信；离线结果如何通过权限受控的接口和图表支持学习复盘。论文的专业技术内容来自实际 Spark 程序、数据分层和实验。

3.2 首版完成标准

优先级	交付内容	完成判断
必做	当前代码与接口基线、三个指标口径	状态与契约可核对，不重复列已完成整改
必做	白名单快照抽取、数据字典与固定小样本	数据来源、粒度、时区和异常规则明确
必做	PySpark 清洗、Spark SQL 聚合及批次重跑	已知答案正确，相同输入结果稳定
必做	汇总发布、只读接口及本人分析页面	源样本至图表全链路可追踪
必做	正确性与规模实验、论文和答辩材料	有原始结果、解释与复现步骤
选做	管理员汇总、社区浏览与教学分析	单独明确权限、数据源和指标
选做	AI 草案生成与分步实践引导	完整等待、提交、反馈及恢复闭环
后续需求	生产额度治理、真实试点、Kafka / Flink、集群	按学校要求或实际使用场景另行确定

达到首版标准后优先收尾论文与答辩。系统已有的社区、教学和 AI 功能继续提供场景与数据，不要求把所有模块同时扩展成新的研究方向。

4 新增数据管道与当前数据模型

4.1 目标数据流



离线作业与 Web 服务分开。图表 GET 查询读取已发布结果，不现场启动 Spark。原 /statistics 接口保持现有业务聚合含义，新接口显示数据集、批次、截止时间和规则版本。

4.2 核心数据源与可信来源

数据源	首版使用的字段或关系	当前限制
learning_records	id、user_id、关联 ID、record_type、duration_minutes、occurred_at、created_at	记录可编辑删除，没有 updated_at；分钟由用户填写
daily_tasks	id、user_id、plan_id、project_id、status、scheduled_date、completed_at	当前状态快照，不是完整状态事件流
feedback	learning_record_id、decision、必要关联 ID	仅为可信教学来源关联，不抽取评阅正文
projects / learning_plans	ID、所有者、必要关联与状态	作为关系维度，不能用展示进度代替任务计数
project_views 选做	id、project_id、user_id、viewed_at	已记录社区详情浏览，刷新重试可能增加 PV
submissions / submission_versions 选做	班级、任务、学生成员、截止快照、版本、提交时间	只记录成功落库版本，正常接口拒绝逾期提交

CR6B 后，分析不能仅用 record_metadata.source 判断“教学生成”。抽取时通过 feedback.learning_record_id 连接记录，且 decision 为 ACCEPT，才派生可信教学来源；其他记录按普通记录或明确异常分类。历史 JSON 即使写有 source，也不能单独成为来源证明。

新建和修改接口禁止客户端提交 source、submission_id、version_number 等系统保留键。来源字段的输出由服务端依据真实关系生成。DWD 应复用同一含义，只导出必要关联事实，不把整个 JSON 或评阅内容带入数据集。

4.3 ODS 与更新策略

第一版按统计窗口抽取完整快照，不使用最大 ID 或 created_at 假装捕获修改删除。一次受控只读一致性事务取得所需字段后尽快结束，Spark 清洗和模型调用均在该事务之外。多个独立 JDBC 连接不能自动视为同一快照。

每批保存 batch_id、dataset_kind、统计窗口、timezone、source_cutoff、抽取时间、源行数和 metric_version。固定快照保持不可变，用于复算和实验。初始抽取可使用明确字段的 CSV，再由独立数据环境转换为 Parquet；所有文件均使用显式 schema。

不抽取密码、Token、邮箱、邀请凭证、完整项目正文、代码或 AI 提示词。性能合成数据直接生成独立文件，与演示业务快照分开。真实库写入及迁移在实施阶段明确目标与授权，不沿用历史测试库名称作为自动写入依据。

4.4 DWD 与质量规则

核心明细为学习记录事实和任务批次快照，教学来源为关系派生字段。按源主键去重：相同内容重复可以去除，同主键冲突内容进入异常记录，不能任意留一条。字段类型、状态、时间、关联和分钟范围均有明确规则。

教学自动记录可有 NULL 时长，保留缺失数，不补成真实学习分钟。当前记录 API 的分钟范围为 1 至 1440 或 NULL，而数据库允许历史零值；零、NULL 和不符合当前 API 范围的数据在字典中单独定义处理方式，不能混为同一种缺失。

DATETIME 沿用 UTC 存储，按 Asia/Shanghai 归属业务日；查询采用本地起始日零点到结束日次日零点的左闭右开窗口，再转换为 UTC。scheduled_date 是 DATE，直接作为计划日期，不再次转换时区。

质量报告记录源行数、去重后行数、有效数、异常数及原因；总数关系能够核对，样本能定位回源主键。按记录统计，不因用户或项目关联缺失就默默丢弃已存在的分钟。

4.5 ADS 与批次发布

核心版先设计批次元数据和用户日汇总两类结果表，拟名 analytics_batches、analytics_learning_daily。后者按 batch_id、user_id、biz_date 唯一，保存记录数量、分钟、缺失数、来源分类及任务各状态计数。新增表和索引在 D3 实施前核定，保持业务表原职责。

汇总先写未发布批次，经质量核对后在短事务内标记 completed；查询只读取已完成批次。已发布汇总禁止覆盖，同输入重试复用结果，需要重算时创建新批次；只有未发布批次可以清理并重写自己的暂存与结果。

前端一次选定 batch_id，所有图表固定使用该批次。发布失败时继续提供上一成功结果，并明确其截止时间。普通用户只能读取授权的本人批次与行；管理员总体和教师班级分析作为选做单独设计。

5 核心指标与数据权限

5.1 首版三个指标

指标	口径	展示规则
已记录学习分钟	按 occurred_at 业务日求和非 NULL 的 duration_minutes	同时显示记录数与缺失数，说明属于记录值
记录活跃天数及来源	本人周期内去重存在学习记录的 biz_date，按普通 / 可信教学来源拆分	不解释为登录活跃、停留时长或真实专注时长
按计划日期任务完成率	completed 数 / 该 scheduled_date 下全部保留任务数	保存分子分母和取消数，分母为零显示无样本

第三项沿用现有报告包含 cancelled 的分母。例如 4 个保留任务中完成 2 个、进行中 1 个、取消 1 个，完成率为 2 / 4。以后如需排除取消任务，使用新的 metric_version，同步文档和图表。

CR6A 已修正“百分比四舍五入等于 100 就允许完成计划”的问题。分析同样必须使用任务分子分母：199 / 200 是 99.5%，不能凭计划展示字段为 100 推断全部完成；空计划不能解释为已完成。任务 completed_at 和 scheduled_date 分别代表完成时间和计划日期，按不同问题使用。

5.2 选做指标与限制

管理员总体汇总可增加有记录用户数，定义为业务日内去重 user_id。首页专注计时、登录频次、匿名访客和 API 请求成功率，需要相应的服务端事件记录，不能从界面、提交表或当前记录数量倒推出结论。

社区可统计已记录 project_views 的 PV 与账号 UV。教学可统计首版提交提前量，即截止快照减首版 submitted_at 的分钟数，展示分布、样本数和缺失数；正常 API 拒绝逾期提交，因此首版按时率通常为 100% 或无样本，只适合核验截止规则。

技术栈数量可保留现状；现有前 N 项百分比不直接当作全量占比引用。若扩展技术栈趋势、工作流成功率或 AI 用量，先定义分母、时间字段、NULL 和数据覆盖，再新增指标，不把未记录用量当成零。

5.3 权限与页面

首版优先做本人分析页，复用现有 ECharts 和 Campus Studio 样式，显示批次、统计周期、来源、截止时间、完成时间和口径版本。页面包含分钟趋势、记录活跃与来源、任务状态和完成率，支持日期选择、空结果与失败提示。

普通账号只看本人汇总；同班教师的权限限于当前授权的教学任务分析；管理员总体是明确授权的汇总。learning_records 和 daily_tasks 没有 class_id，不能把班级关系当作读取所有个人学习数据的授权。

合成数据只用于独立规模实验；如果增加实验展示，提供受控汇总并明确 synthetic 标记，不能混入个人历史或声称有真实用户规模。

6 新版分阶段实施安排

D0 固定新基线与契约

建议半天至一天。以本版为入口确认题目、三个指标和最小演示；导出当前 OpenAPI，整理接口模块、角色范围与 CR 行为变化。把 CR1 至 CR9 列为已完成回归基线，不再作为首批功能开发。

收口现有错误文档：实际 error.code / message / request_id 与 OpenAPI 的 422 描述仍不一致。先给出兼容说明、接口文档和必要契约样本；改变公开返回字段时单独确认。同步过时的 PRODUCT、知识网络或论文描述，但保留历史报告原日期和原结论。

交付物：范围页、需求到实现与验证矩阵、指标卡、接口契约基线。验收：当前能力、拟新增能力和选做清楚；每项核心要求有完成依据。

D1 环境与小样本快照

建议两至三天。核对 Python、JDK、内存与磁盘，选择并固定可验证的 Spark 版本，在独立数据环境完成最小 CSV / Parquet 读写与聚合。新增依赖先给具体版本及影响，不改变后端已有虚拟环境。

实现学习记录、任务和必要 Feedback 事实的白名单抽取；固定小样本与手算答案，覆盖普通记录、真实教学关系、历史伪 JSON、NULL、零、跨午夜、取消和空任务。定义数据字典、snapshot 与目录规则，再形成 ODS。

交付物：环境说明、抽取入口、快照、元信息和预期结果。验收：记录分钟和来源均可核对；输入不包含秘密或无关正文；快照能够稳定复用。

D2 PySpark 与 Spark SQL

建议三至五天。按第 4、5 节实现显式 schema、来源关系、去重、异常分流与日期转换。DataFrame 负责规范明细，Spark SQL 负责三个指标的聚合；输出 DWD、ADS 和质量计数。

先与手算答案比较，再验证同快照与规则重跑得到相同结果。保留作业参数、退出状态和失败原因，入口可以通过命令行复现，不只保留 Notebook 截图。

交付物：清洗与聚合作业、异常样本、指标结果与规则测试。验收：所有已知答案正确；199 / 200、可信来源、NULL 和无样本规则保持准确。

D3 汇总发布与系统展示

建议三至五天。先审查新增结果表、增量迁移、批次发布和只读接口，再按确认后的设计实施。只写分析汇总，不覆盖现有学习记录、工作流结果或 AI 报告。

增加本人离线分析页面，API 从认证上下文确定 user_id，不能接受任意用户 ID。前端复用 CR4 的账号切换、请求归属和最新响应处理，日期切换时避免旧批次覆盖新结果。

交付物：迁移与回退说明、导入发布入口、接口契约和页面。验收：固定样本能追踪至 MySQL、API 和图表；失败不发布半批次；跨用户拒绝；退出与切换账号不泄漏汇总。

D4 实验与回归

建议三至五天。小样本做正确性；固定种子生成两至三档合成文件做规模实验。候选一万、十万、一百万条，按本机能力试跑后选定实际规模，记录真实行数、分布和输出。

固定输入与指标规则，与 Python 标准库实现或受控 MySQL 结果比较。先比较答案，再测量耗时；区分抽取、Spark 启动、清洗、聚合、发布和端到端时间，预热后至少测量三次，记录原始值、中位数与范围。

在专用测试环境补做新分析的真实 API 与页面主线，并按变更影响运行相关 CR 回归。现有 CR9 验收证明原业务，新分析仍需自己的证据。数据写入前核对明确目标和空库状态，测试清理只处理本次资源。

交付物：实验环境、生成规则、原始测量、分析图和回归记录。验收：同口径、可复现、不挑选结果；合成与真实数据分开；失败、越权、重跑及清理均有结果。

D5 论文与答辩

建议三至四天，从 D0 起同步积累材料。围绕已完成的数据链路、关键代码、实验和权限说明撰写论文，统一数据字典、接口、图表标签和论文章节。

冻结一套演示样本与成功批次，准备十分钟脚本、截图或视频和失败恢复案例。使用 CR9 的原业务证据作为基础，新增 Spark 与图表证据作为本次专业主线；不能把 Fake Provider 当作真实模型质量结论。

交付物：论文、PPT、演示材料、关键代码导读和导师问答。验收：本人能从一条记录解释到指标、批次、接口和图表，也能解释何处使用 AI、何处由确定性规则验证。

7 代码与全部接口的规范方法

7.1 现有接口如何维护

附录 A 列出当前全部 136 项操作。按模块补齐契约卡，记录用途、调用页面、方法与路径、请求与响应 Schema、真实错误、资源归属、分页、排序、时间、版本、幂等及验证用例。公开握手、个人资源、校园教学和治理接口均在范围内。

接口数量不变时也要更新行为说明，尤其是工作流活动运行保护、CR5 显式 null、CR6 保留来源字段、CR7 新邀请恢复规则和 CR8 分页。现有 PUT 的部分更新约定如实说明，避免为风格统一批量改成 PATCH。

现有错误返回与 OpenAPI 应保持一致，401 / 403 / 404 / 409 / 422 等按真实实现描述。字段错误位置可作为后续兼容改进，避免在本轮文档任务中默认实施新的公开返回结构。

7.2 一个应能讲清的现有接口

POST /api/v1/learning/tasks/{task_id}/complete 通过当前用户与所有权校验，检查任务和计划状态，使用当前计划与任务状态更新完成数量和进度，再返回任务 DTO。重复完成已完成任务不增加次数；它不会自动生成一条手工学习记录。计划完成另外检查真实 total 大于零且 completed 等于 total，不能用四舍五入后的 progress 代替。

新增分析接口也要达到这种可解释程度：数据来自哪个批次、按哪个时间统计、谁能查询、分母为什么这样选、失败怎样表示，都能回到具体代码和测试。

7.3 新代码与冗余控制

前端保持页面组合、API 适配与 Store 状态的职责，复用已有组件与领域函数；不要在多个页面各算一遍统计分母。数据管道独立组织 extract、transform、aggregate、load 和 tests，按当前阶段创建所需目录，不构建通用 ETL 平台。

服务端继续用 Schema 校验、Service 授权与业务规则、Repository 查询。复用 CR 已建立的锁顺序和短事务约定，避免为分析读取重新引入模型等待期间的事务。工作流路径的事务改善不能自动推断为所有独立 Agent 和学习报告路径都已改完；这些次要改进在有具体影响时单独处理。

现有学习进度查询已复用任务计数，旧计划所列重复计算要重新按调用关系判断。只清理有证据无用的代码，不删除历史提交、快照或审计，也不按固定行数机械拆模块。

8 新增数据库与分析接口草案

8.1 最小数据结构

analytics_batches 记录窗口、时区、dataset_kind、source_cutoff、metric_version、状态、质量数量和耗时；analytics_learning_daily 保存本人日粒度结果及任务分子分母。两类表为拟议结构，具体类型、唯一键和索引在 D3 形成可审查设计。

按批次和 user_id、biz_date 查询设置必要索引；比例由已保存的分子分母计算。数据库验收既核对新增表的名称，也核对类型、可空性、默认值、唯一约束与索引列，避免仅凭同名约束判断迁移正确。版本、快照和原有 34 张表继续保留。

8.2 拟议只读契约

下列接口尚未实现，属于 D3 设计草案；新增公共 API 和数据结构的影响在实施前确认。

拟议方法与路径	用途与范围	关键返回
GET /api/v1/analytics/offline/batches	本人可用完成批次；总体批次需明确权限	批次、窗口、来源、截止时间、规则版本
GET /api/v1/analytics/offline/me/daily	本人日汇总，user_id 由认证决定	分钟、缺失数、来源、任务分子分母

拟议方法与路径	用途与范围	关键返回
GET /api/v1/analytics/offline/admin/overview	选做；管理员授权总体汇总	有记录用户数、分钟、任务与质量数量
GET /api/v1/analytics/offline/classes/{class_id}/assignments	选做；当前同班教师任务分析	提交提前量、样本和缺失数

参数包含 batch_id、起止日和有界分页。响应带 dataset_kind、timezone、source_cutoff、metric_version；无可用批次与空列表分别表达，分母为零返回 NULL 并显示无样本。服务端验证批次范围与窗口，不允许拼接任意文件路径或读取任意用户结果。

第一版通过受控 CLI 发起作业。没有实际使用需要时，不新增 HTTP 作业启动、任意代码执行或复杂调度能力。

9 实验与验证设计

9.1 正确性矩阵

场景	应验证的结果
普通记录与真实教学来源	仅 ACCEPT Feedback 关系派生教学来源，分钟与 NULL 分开
历史伪造 JSON 来源	不被认定为教学通过记录
UTC 午夜与业务 DATE	日期归属正确，scheduled_date 不发生二次偏移
199 / 200 与空计划	分子分母准确，不把展示整数当完成资格
取消、无记录与无样本	分母和状态拆分清楚，NULL 不变成成功率零
源记录修改或删除	新快照重算反映变化，旧批次保持可追溯
重复主键与冲突内容	相同重复可去重，冲突有明确异常原因
发布失败、重试与重算	不覆盖已完成批次，不展示半成品
账号和日期快速切换	没有旧数据泄漏或陈旧响应覆盖
个人与跨班访问	本人可读，越权拒绝，教师不读取私人学习全量

9.2 规模与性能

采用单机 local 模式先完成实验，建议固定如 local[2] 的线程设置并记录实际参数。数据量按本机试跑确定，固定种子、用户数、日期跨度、异常比例与分区。百万条候选样本不等于必须把百万条记录写入业务库。

对照实现使用同一快照、同一过滤、NULL、来源和分母规则，分别统计计算耗时与全流程耗时；使用 MySQL 对照时说明输入载入成本。小数据下 Spark 启动可能占较大比例，以实测解释性能，不预设更快。可选记录 explain、任务阶段与 shuffle，帮助说明瓶颈。

每组保留至少三次预热后测量，报告中位数、范围、输出行数和异常。单机并行实验只说明本机环境，集群扩展能力作为展望；合成规模也不当作真实师生使用规模。

9.3 验证工具与证据

已有 unittest、CR 专项、verify_integration.py 与真实浏览器主线继续作为基础。新增管道先测试纯清洗与小样本聚合，再测试结果发布和新 API；共享认证或前端状态发生变化时补跑相应 CR4 场景，工作流未改则不盲目重写其测试。

前端沿用 pnpm typecheck、pnpm build；后端运行与变更有关的 unittest 及必要依赖检查。仓库没有独立 Lint / 格式化 / 安全扫描命令时如实记录，不安装一整套工具来满足形式。历史构建的 Analytics 大包提示按实际影响处理，不作为阻止 Spark 开发的前置任务。

每次保存输入批次、命令参数、软件环境、实际结果与必要截图。API、页面、计算正确性、真实模型质量和课堂使用效果分开验证。历史失败日志保留，最终结论指向对应成功复验。

10 AI 与其他后续路线

10.1 现有 AI 能力继续复用

已有 Agent、Context、工作流记录和 AI 报告可用于演示应用价值。CR 已完善字段读取和图运行一致性，新增离线分析不应反向修改这些约定。AI 可解释学习数据，但核心指标由确定性规则产生，保存生成时输入事实。

完整 AI 引导方案继续按 W0 场景与契约、W1 草案生成、W2 等待提交与分步调用、W3 成果落实、W4 质量评价推进。若选择实施，先用固定 CSV 清洗练习，保留旧 DAG 模式，独立设计引导会话、尝试版本与恢复；只有生成画布不能算完整引导。

10.2 本次毕业交付之后

社区浏览、教学提交提前量可在核心指标稳定后加入。平台额度治理、公开部署、隐私与真实课堂试点在具体使用条件下分别推进。AI 测试入口向非受控账号开放前应收紧；独立 Agent 和报告调用的连接占用按实际风险收尾，不把它扩展成整套生产平台改造。

Kafka / Flink 需要明确的事件采集、重放、延迟与一致性实验，待离线主线完成后再决定。Hadoop 集群、复杂调度、任意学生代码执行和自动判题均不进入核心版。

11 论文与答辩材料

11.1 章节与证据

章节	核心内容与应有材料
绪论与技术背景	问题、范围、相关研究，Spark 与数据处理方法
需求与总体设计	需求矩阵、角色权限、现有业务与新增管道边界
数据与指标设计	源字段、可信关系、分层、时间、NULL 和分母
数据处理实现	抽取、DataFrame、Spark SQL、异常与批次发布
系统展示与接口	结果表、新 API、前端图表及原业务复用
测试与实验	已知答案、规模、性能、越权、失败恢复与回归
总结与展望	实际完成范围、单机局限、选做与实时扩展

至少准备总体数据流、核心 ER、分析表关系、批次发布时序、指标字典、权限矩阵和实验结果图。代码整改作为工程质量与关键设计证据使用，不把缺陷数量当作研究创新指标。

11.2 十分钟演示

第一分钟介绍场景与目标；第二分钟展示记录、任务和可信教学来源；第三至第五分钟展示固定快照、异常处理和 Spark 聚合；第六至第七分钟从批次、API 到图表核对结果；第八分钟解释规模实验；第九分钟展示失败或越权处理；第十分钟说明结论与后续工作。

演示准备固定小样本与已完成批次，Spark 全流程保留可复现命令和备用录屏。现场能讲解 learning 真实计数、Feedback 来源、抽取、清洗、SQL、发布和查询七处关键代码即可，不需要逐项展示全部 136 个接口。

11.3 导师常见问题

问题	回答依据
这次改了很多，新增了什么大数据能力	CR 是业务质量基础；以实际完成的 Spark 管道和实验回答新增部分
为什么同时保留 MySQL 和 Spark	MySQL 服务事务与图表查询，Spark 处理批量清洗、关联和聚合
为什么不直接把 progress 当完成率	展示整数会四舍五入，199 / 200 与真实全部完成不同
教学记录如何保证来源可信	展示 Feedback.learning_record_id 和 ACCEPT 关系，客户端来源键受限
分钟是否等于真实学习时间	是已记录分钟，NULL、来源与数据采集边界明示
为什么不直接按最大 ID 增量	记录可修改删除且无 updated_at，首版采用窗口完整快照
重跑或失败会不会改坏历史图表	不可变输入、完成批次不覆盖、失败保留上一成功结果
Spark 是否更快、数据是否真实	出示同口径测量、单机参数及真实 / 合成数据区分
原系统有没有被破坏	说明既有契约、CR9 基线与新增后的相关回归
本人做了什么、AI 做了什么	按真实记录解释需求、设计、实现、验收和辅助工具，能独立讲关键代码

12 时间安排与每阶段停止条件

建议预留四至六周，按已有资料与学习速度调整：第一周完成 D0、D1；第二周 D2；第三周 D3；第四周 D4；随后完成 D5 与论文修改。论文资料从第一周同步积累，不把全部写作留到最后。

时间紧时保留三个核心指标、本人页面、固定样本、两档规模实验和完整答辩主线，减少选做。时间充足时选择一个扩展，不同时启动 AI 引导、实时计算和生产部署。

阶段	进入下一阶段的条件
D0	范围、指标、权限与接口基线一致
D1	环境最小作业通过，数据样本与预期答案固定
D2	三指标与答案一致，同输入重跑稳定
D3	发布、API、页面与跨用户隔离闭环
D4	原始实验、正确性、回归和清理证据完整
D5	论文、演示与代码讲解采用同一事实和口径

后续阶段需要依赖、API 或数据结构变更时，先形成具体设计和兼容说明再确认实施。当前文档交付不等于已批准所有未来迁移或写库操作。

13 执行清单与资料维护

近期顺序为：固定本版基线与三个指标；补接口和旧描述；准备独立数据环境与小样本；实现 Spark；接入本人图表；完成实验；收尾论文。CR1 至 CR9 只作为保持通过的回归集合。

最终交付应有范围页、需求矩阵、数据字典、当前接口目录与契约卡、可运行管道、固定快照与预期答案、质量报告、批次结果、新 API、页面、实验原始值、论文、PPT、演示和关键代码说明。

R0 对应 D0；R1 在全过程积累；R2 复用 CR9 原业务主线并补新增分析；R3A 对应 D4；R3B 随真实模型评价选做；R4、R5 在 D5 收尾。L1 至 L3 与 CR6 的当前实现保留；旧 L4 缺口已由最新主线证据补齐；L5 统计口径和 L6 调试入口仍按实际用途安排。

现状依据：当前源码与 OpenAPI；20261016-CR9-严格审查整改最终验收报告；CR9 的 07-live-browser-retest.log；20261016-GitHub检查与推送报告；CR1 至 CR8 阶段报告。旧 20261015 计划用于版本对照，不覆盖新版待办。

技术参考：Spark 固定版本安装说明、Spark Parquet 数据源。实施时按最终固定版本核对 Python / Java 兼容与实际运行；引用这些文档不表示本机数据环境已经安装。

附录 A 当前全部接口清单

以下由本版编制时实际生成的 OpenAPI 提取，共 17 个模块、96 个路径、136 项操作。路径统一省略 /api/v1；详细字段以对应 Schema 和 /docs 为准，实际业务授权以 Service 为准。第 8 节拟新增接口不计入现有目录。

服务状态 health

1 个路径，1 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/health	服务健康检查

认证 auth

7 个路径，7 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
POST	/auth/slider/challenge	获取一次性滑块挑战
POST	/auth/slider/verify	校验滑块并签发一次性登录凭证
POST	/auth/register	注册用户
POST	/auth/login	用户登录
POST	/auth/change-password	修改当前账号密码
POST	/auth/logout-all	撤销当前账号全部会话
POST	/auth/reset-password	使用一次性凭证重置密码

校园身份 campus

9 个路径，9 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/campus/me	获取本人校园身份
POST	/campus/invitations	签发校园邀请
POST	/campus/invitations/redeem	兑换本人校园邀请
GET	/campus/admin/accounts	查询校园账号
PATCH	/campus/admin/accounts/{user_id}	变更账号或校园身份
GET	/campus/admin/invitations	查询校园邀请
POST	/campus/admin/invitations/{invitation_id}/revoke	撤销校园邀请
POST	/campus/admin/accounts/{user_id}/password-resets	签发一次性密码重置凭证
GET	/campus/admin/audits	查询账号管理审计

教学班与任务 campus-teaching

9 个路径，14 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/campus/classes	查询可访问的教学班
POST	/campus/classes	教师创建教学班
GET	/campus/classes/{class_id}	获取教学班详情
PATCH	/campus/classes/{class_id}	编辑或归档教学班
GET	/campus/classes/{class_id}/members	查询教学班成员
POST	/campus/classes/{class_id}/members	增加教学班成员
PATCH	/campus/classes/{class_id}/members/{member_id}	退出或移除教学班成员
GET	/campus/classes/{class_id}/assignments	查询教学班任务
POST	/campus/classes/{class_id}/assignments	创建教学任务草稿
GET	/campus/assignments/{assignment_id}	获取教学任务详情
PATCH	/campus/assignments/{assignment_id}	修改教学任务
POST	/campus/assignments/{assignment_id}/publish	发布教学任务
POST	/campus/assignments/{assignment_id}/close	关闭教学任务
POST	/campus/assignments/{assignment_id}/archive	归档教学任务

成果提交与反馈 campus-submissions

9 个路径，10 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
POST	/campus/assignments/{assignment_id}/submissions	提交成果或追加版本
GET	/campus/assignments/{assignment_id}/submissions	查询指定任务的提交
GET	/campus/submissions	查询本人提交或教师待评列表
GET	/campus/submissions/pending-assignments	查询学生待提交或待修改任务
GET	/campus/submissions/{submission_id}	获取提交详情
GET	/campus/submissions/{submission_id}/versions	分页查询提交版本历史
POST	/campus/submissions/{submission_id}/versions/{version_number}/feedback	教师退回或确认通过指定版本
DELETE	/campus/submissions/{submission_id}/versions/{version_number}/project-reference	本人解除提交版本的项目来源关联
GET	/notifications	查询本人站内通知
POST	/notifications/{notification_id}/read	标记本人通知为已读

当前用户 users

1 个路径，1 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/users/me	获取当前用户

个人项目 projects

2 个路径，5 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/projects	获取当前用户的项目列表
POST	/projects	创建项目
GET	/projects/{project_id}	获取项目详情
PUT	/projects/{project_id}	更新项目
DELETE	/projects/{project_id}	删除项目

项目上下文 project-context

3 个路径，5 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
POST	/projects/{project_id}/context	从项目创建 ProjectContext
GET	/projects/{project_id}/context	读取 ProjectContext
PUT	/projects/{project_id}/context	更新 ProjectContext 并标记依赖节点过期
POST	/workflows/{workflow_id}/nodes/{node_id}/context/read	按节点权限读取 ProjectContext
POST	/workflows/{workflow_id}/nodes/{node_id}/context/write	按节点权限写入 ProjectContext

平台统计 statistics

4 个路径，4 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/statistics/today	查询今日平台统计
GET	/statistics/trend	查询平台趋势
GET	/statistics/projects	查询项目统计
GET	/statistics/tech-stacks	查询技术栈统计

社区与治理 community

19 个路径，23 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/community/projects	浏览校园社区项目
GET	/community/projects/{project_id}	获取社区项目详情
GET	/community/tags	获取社区项目标签
POST	/projects/{project_id}/publication-requests	申请发布或更新社区作品
GET	/projects/{project_id}/publication	查询本人项目发布进度
GET	/community/publications/mine	查询本人发布申请
POST	/community/publications/{publication_id}/withdraw	撤回社区发布
GET	/community/moderation/publications	查询待审核社区作品
POST	/community/moderation/publications/{publication_id}/decisions	审核或下架社区作品
POST	/community/reports	举报社区项目或评论
GET	/community/governance/cases	查询本人相关或管理员待处理案件
POST	/community/moderation/actions/{action_id}/appeals	对下架或隐藏动作申请复核
POST	/community/moderation/cases/{case_id}/decisions	处理举报或复核
POST	/projects/{project_id}/publish	旧发布入口
DELETE	/projects/{project_id}/publish	兼容撤回社区项目
POST	/projects/{project_id}/view	记录项目浏览
GET	/projects/{project_id}/comments	获取项目评论
POST	/projects/{project_id}/comments	发表评论
DELETE	/comments/{comment_id}	删除自己的评论
POST	/projects/{project_id}/like	点赞项目
DELETE	/projects/{project_id}/like	取消点赞项目
POST	/projects/{project_id}/favorite	收藏项目
DELETE	/projects/{project_id}/favorite	取消收藏项目

个人工作台 workspace

6 个路径，8 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/workspace/dashboard	获取个人工作台聚合数据
GET	/workspace/tasks	获取个人任务
POST	/workspace/tasks	创建个人任务
POST	/workspace/tasks/{task_id}/complete	完成个人任务
GET	/workspace/projects	获取工作台项目进度
GET	/workspace/projects/{project_id}	获取工作台项目详情
GET	/workspace/records	获取个人学习记录
POST	/workspace/records	保存学习记录

课程 courses

2 个路径，5 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/courses	获取我的课程
POST	/courses	创建课程
GET	/courses/{course_id}	获取课程详情
PUT	/courses/{course_id}	更新课程
DELETE	/courses/{course_id}	Delete Course

学习管理 learning

7 个路径，16 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/learning/plans	获取学习计划列表
POST	/learning/plans	创建学习计划
GET	/learning/plans/{plan_id}	获取学习计划详情
PUT	/learning/plans/{plan_id}	更新学习计划
DELETE	/learning/plans/{plan_id}	删除学习计划
GET	/learning/tasks	获取每日任务列表
POST	/learning/tasks	创建每日任务
GET	/learning/tasks/{task_id}	获取任务详情
PUT	/learning/tasks/{task_id}	更新每日任务
DELETE	/learning/tasks/{task_id}	删除每日任务
POST	/learning/tasks/{task_id}/complete	完成每日任务
GET	/learning/records	获取学习记录列表
POST	/learning/records	创建学习记录
GET	/learning/records/{record_id}	获取学习记录详情
PUT	/learning/records/{record_id}	更新学习记录
DELETE	/learning/records/{record_id}	删除学习记录

个人学习报告 learning-reports

2 个路径，3 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
POST	/learning-reports	生成当前用户的 AI 学习报告
GET	/learning-reports	查询学习报告列表
GET	/learning-reports/{report_id}	查询学习报告详情

工作流 workflows

10 个路径，20 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
GET	/workflows	获取当前用户的工作流列表
POST	/workflows	创建工作流
POST	/workflows/{workflow_id}/run	运行或重新生成工作流
GET	/workflows/{workflow_id}/runs	获取 WorkflowRun 列表
GET	/workflows/{workflow_id}/runs/{run_id}	获取 WorkflowRun 详情和节点结果
GET	/workflows/{workflow_id}/graph	读取完整工作流图
PUT	/workflows/{workflow_id}/graph	原子保存完整工作流图
GET	/workflows/{workflow_id}/nodes	获取工作流节点列表
POST	/workflows/{workflow_id}/nodes	创建工作流节点
GET	/workflows/{workflow_id}/nodes/{node_id}	获取工作流节点详情
PUT	/workflows/{workflow_id}/nodes/{node_id}	更新工作流节点
DELETE	/workflows/{workflow_id}/nodes/{node_id}	删除工作流节点
GET	/workflows/{workflow_id}/edges	获取工作流边列表
POST	/workflows/{workflow_id}/edges	创建工作流边
GET	/workflows/{workflow_id}/edges/{edge_id}	获取工作流边详情
PUT	/workflows/{workflow_id}/edges/{edge_id}	更新工作流边
DELETE	/workflows/{workflow_id}/edges/{edge_id}	删除工作流边
GET	/workflows/{workflow_id}	获取工作流详情
PUT	/workflows/{workflow_id}	更新工作流
DELETE	/workflows/{workflow_id}	删除工作流

AI 调试 ai

1 个路径，1 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
POST	/ai/test	测试统一 AI Provider

Agent agents

4 个路径，4 项操作。路径省略统一前缀 /api/v1。

方法	路径	用途
POST	/agents/project-analysis	运行项目分析 Agent
POST	/agents/prompt	运行开发 Prompt Agent
POST	/agents/project-review	运行项目审查 Agent
GET	/agents/results/{request_id}	查询当前用户的 Agent 结果

附录 B 独立阶段开发指令

D0 指令

依据本版方案和当前工作区整理题目、范围、三个指标、权限和接口契约。先核对 CR1 至 CR9 的当前实现与证据，把已完成事项移出待开发。导出 OpenAPI 并列出旧描述和错误契约的最小修改，保留所有已有路径与字段；需要改变公开返回时先给兼容方案，不批量改名或重构。交付范围页、指标卡与规范收口清单。

D1 指令

只做独立数据环境与固定小样本。先检查并提出可验证的 Python / JDK / Spark 版本方案，确认新增依赖后再安装。抽取 learning_records、daily_tasks 与必要 Feedback 事实，可信来源依据 ACCEPT 关系，不相信任意 JSON.source。保持 UTC、DATE、NULL 与历史零值的差异，采用窗口快照，不向业务库灌入大规模数据。交付数据字典、快照、元信息与正确答案。

D2 指令

只实现三个核心指标的 PySpark 清洗与 Spark SQL 聚合。用显式 schema 处理去重、冲突、来源、时间和异常；先核对固定答案，覆盖 199 / 200、取消、空任务、NULL 和历史伪来源，再验证同输入重跑一致。输出 DWD、ADS、质量计数、参数和结果，不扩展实时平台或工作流执行语义。

D3 指令

先给结果表、增量迁移、发布机制和只读 API 的具体设计，取得对应变更确认后实施。完成批次不能覆盖；失败保留旧结果；本人查询由认证确定 user_id。复用现有账号隔离与最新请求机制，保留原 statistics 和 CR 行为。交付发布入口、契约、页面及真实查询、越权和切换场景证据。

D4 指令

先固定环境、数据规模、种子、分布、测量阶段和对照规则，再生成独立合成文件。先验证答案，再按同一口径测量，至少保存三次预热后原始结果，不预设 Spark 更快。新分析端到端测试使用明确确认的专用环境；相关 CR 按变更影响回归。交付原始数据、分析图、复现命令和清理结果。

D5 指令

只依据实际完成阶段整理论文、PPT、演示和关键代码导读。统一指标、接口、批次和实验数字；以新 Spark 数据链路为主，原业务与 CR 作为复用基础。准备导师问答、固定案例和录屏，区分 AI 建议、结构校验、真实运行和人工核对，未实现能力放入后续计划。